刘晓东

AI 应用开发工程师 RAG · Agent · Python

1105185454@qq.com

现居山东滨州 · 期望：济南 / 可远程 · 随时到岗

线上作品：ops.liuxd.dev · 代码：github.com/roccowork/ai-portfolio

个人优势

- **做过真正上线运行的 AI 应用**：独立开发并运维 ops.liuxd.dev 上的运维 Agent（告警自动排查与自愈）、RAG 知识库问答、ChatBI（一句话查数据），从设计、开发、评测到部署监控一人完成，代码全部公开。
- **用评测数据驱动改进，安全靠程序兜底**：为 RAG 和 Agent 建了 3 套共 82 道题的评测集，每次改动都用分数验证；权限、费用、数据隔离用代码强制，不依赖提示词。
- **11 年制造企业 IT + 扎实的运维功底**：懂企业系统（用友 ERP、Oracle）和真实业务；熟悉 K8s、GitOps、监控告警，能把 AI 应用稳定部署到生产环境。

专业技能

RAG	文档切块（按标题、代码块和表格不拆）、向量检索 + BM25 关键词检索、RRF 融合排序、引用出处、资料里没有时拒答；向量按内容哈希缓存
Agent	Function Calling 多轮工具调用、人工确认（Human-in-the-loop）、提示词注入防护、回答与工具调用的一致性核对；了解 Dify
数据	Text-to-SQL（语义层、只读执行、报错自动修正）；SQL、pandas 数据分析（IBM Data Analyst 证书）
评测	评测集设计；检索指标（命中@k、MRR）、要点命中、LLM 裁判、拒答率；故障注入式 Agent 评测
后端	Python、FastAPI、异步 httpx、SQLite / MySQL、pytest；模型网关：多模型降级、按 token 计费、费用上限与限流、Prometheus 指标
部署运维	Docker、k3s / Kubernetes、Argo CD（GitOps）、GitHub Actions、Prometheus + Grafana + Alertmanager、cert-manager、restic 备份；Linux、Nginx、Ansible
前端	Astro、Vue（能独立完成 AI 功能的交互页面）

AI 项目

线上运行 · ops.liuxd.dev · 代码公开 · 2026.10 – 至今

运维 Agent 与告警自愈

Agent

Function Calling · Prometheus API · Kubernetes API · Alertmanager · Telegram Bot

- 给模型 6 个只读工具（告警、Pod、事件、日志、PromQL、运维手册检索）。收到告警后自己排查、给出根因，从 3 种预设操作中提议处置：低风险的自动执行，其余推到 Telegram 由人点「执行」，执行后检查是否恢复。
- 安全靠程序：K8s 账号只读且看不到 Secret，命名空间白名单，日志先脱敏再给模型；写权限只开放 3 种操作，不能处理它自己，同一对象 6 小时内只自动处理一次。
- 故障演练评测：在真实集群数据上注入 OOM、备份超时、拉镜像 401、日志里藏指令等 21 种场景。第 1 次通过率 57%，发现模型没调用工具就编数据、把操作写在文字里；加了「回答引用的工具是否真的调用过」的程序核对和组件对照表。

RAG 知识库问答

RAG

text-embedding-v3 · BM25 · RRF · LLM 裁判 · 评测集

- 两个知识库：作品集问答（访客在网站上提问，可留言）和运维手册问答（作为 Agent 的工具，按手册回答并注明章节）。文档改了只重算变化段落的向量。
- 评测集 61 道题，含 10 道资料里没有答案的题，专测会不会编；指标分检索（命中@1/@3、MRR）和生成（要点命中、裁判判对、引用准确、拒答率）。
- 运维手册检索命中@1 只有 70%：向量对 rateLimited 这类英文专有名词不敏感。改为向量 + BM25 混合检索、RRF 融合，命中@1 提到 85.7%，要点命中和拒答率都到 100%。

ChatBI：一句话查数据 Text-to-SQL

Text-to-SQL · SQLite · FastAPI · Vue

- 用中文问网站自己的真实运行数据（AI 调用与费用、告警自愈、评测分数、访问量、发布记录），模型写 SQL、程序执行、画图并解读；语义层写明表结构、指标口径和「本周」对应的真实日期。
- 安全靠程序：只读连接，授权回调只放行 SELECT，单条语句、最多 200 行、2 秒超时，报错交给模型改一次；每 10 分钟生成只含统计表的快照，留言和联系方式不进库，SQL 怎么写都查不到。

模型网关与部署平台 工程化

FastAPI · k3s · Argo CD · GitHub Actions · kube-prometheus-stack · restic

- 所有模型调用经过自写网关：重试、按 token 估算费用并记账、Prometheus 指标；访客每天合计费用上限 + 每个 IP 每天次数上限，和自己的用量分开计算，被刷也不会超支。
- 单节点 k3s（4 核 12G）按生产标准部署：推送后 GitHub Actions 测试、构建镜像、更新 GitOps 清单，Argo CD 同步上线，回滚用 git revert 约 1 分钟（实测）；监控告警、证书自动续期、每天加密备份到 R2。

运维实战项目 笔记本 VirtualBox 搭建 3–4 台虚拟机 · 2026.09 – 2026.10 · 案例详情 cv.liuxd.dev

- **GitOps 持续交付**：GitHub Actions 测试，Jenkins 构建镜像推送私有仓库，用最小权限 token 更新 GitOps 仓库，Argo CD 自动同步；坏版本过不了就绪探针，旧 Pod 持续服务，git revert 回滚。
- **K8s 与可观测性**：kubeadm 部署 1 主 2 从集群，Helm 安装 kube-prometheus-stack + Loki，编写 PrometheusRule 和 ServiceMonitor。
- **自动化与容灾**：Ansible role 一条命令交付新机器（重复执行 changed=0）；Docker 多阶段构建镜像 300MB → 15MB；MySQL GTID 主从 + binlog 时间点恢复演练；Keepalived 双机热备。

工作经历

AI 应用开发与运维 · 全职学习与实战 2026.09 – 至今

- 完成 16 个运维实战项目；开发并持续运维 ops.liuxd.dev 上的 AI 应用（上面 4 个项目）。

灵活就业 · 业余学习数据分析 2024.08 – 2026.08

- 工作之余学习数据分析课程，2026 年取得 IBM Data Analyst 专业证书（Coursera）。

山东汇金彩钢有限公司 信息技术员 · 约 500 人制造企业 2013.08 – 2024.07

- 负责约 100 台电脑、打印机、办公网络和 VMware 虚拟化平台（3 台物理服务器，为数十台瘦客户机提供虚拟桌面）的日常运维，保障生产与办公系统正常运行。
- 支持用友 ERP：编写 Python 脚本读取数千行 Excel 物料数据，自动在 ERP 中批量创建 BOM，每次向 Oracle 数据库写入数百条记录，替代人工逐条录入。
- 编写 Python 脚本自动汇总每月话费账单（数千行 Excel），替代人工统计。

教育与证书

山东凯文科技职业学院（现山东工程职业技术大学） · 汽车维修 · 大专 2006.09 – 2009.08

IBM Data Analyst Professional Certificate（Coursera） 2026